

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Primož Godec

Barvanje črnobelih slik z globokimi modeli

MAGISTRSKO DELO
MAGISTRSKI PROGRAM DRUGE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: prof. dr. Blaž Zupan

Ljubljana, 2017

AVTORSKE PRAVICE. Rezultati magistrskega dela so intelektualna lastnina avtorja in Fakultete za računalništvo in informatiko Univerze v Ljubljani. Za objavlanje ali izkoriščanje rezultatov magistrskega dela je potrebno pisno soglasje avtorja, Fakultete za računalništvo in informatiko ter mentorja¹.

©2017 PRIMOŽ GODEC

¹V dogovorju z mentorjem lahko kandidat magistrsko delo s pripadajočo izvirno kodo izda tudi pod drugo licenco, ki ponuja določen del pravic vsem: npr. Creative Commons, GNU GPL. V tem primeru na to mesto vstavite opis licence, na primer tekst [?].

ZAHVALA

Na tem mestu zapišite, komu se zahvaljujete za izdelavo magistrske naloge. V zahvali se poleg mentorja spodobi omeniti vse, ki so s svojo pomočjo prispevali k nastanku vašega izdelka.

Primož Godec, 2017

Vsem rožicam tega sveta.

*"The only reason for time is so that
everything doesn't happen at once."*

— Albert Einstein

Contents

Povzetek

Abstract

1	Uvod	1
2	Pregled Področja	5
2.1	Predstavitev slikovnih podatkov in barvni prostori	5
2.2	Obstoječe metode za barvanje črno-belih slik	8
2.3	Globoke nevronske mreže	10
3	Barvanje črno-belih slik z globokimi nevronskimi mrežami	13
3.1	Arhitekture	13
3.2	Pristop z regresijo	13
3.3	Pristop s klasifikacijo	13
3.4	Postopek učenja	13
4	Podatki	15
5	Rezultati in diskusija	17
5.1	Primerjava metod na manjši učni množici	17
5.2	Primerjava metod na večji učni množici	17
5.3	Barvanje večjih slik	17
6	Gradnik v orodju Orange	21

CONTENTS

A	Spearmanova korelacija rangov med metodami	23
----------	---	-----------

Povzetek

Naslov: Barvanje črnobelih slik z globokimi modeli

V vzorcu je predstavljen postopek priprave magistrskega dela z uporabo okolja L^AT_EX. Vaš povzetek mora sicer vsebovati približno 100 besed, ta tukaj je odločno prekratek. Dober povzetek vključuje: (1) kratek opis obravnavanega problema, (2) kratek opis vašega pristopa za reševanje tega problema in (3) (najbolj uspešen) rezultat ali prispevek magistrske naloge.

Ključne besede

Umetna inteligenca, Odkiravanje znanj iz podatkov, globoko učenje, nevronske mreže

Abstract

Title: Deep models for image coloring

This sample document presents an approach to typesetting your BSc thesis using L^AT_EX. A proper abstract should contain around 100 words which makes this one way too short. A good abstract contains: (1) a short description of the tackled problem, (2) a short description of your approach to solving the problem, and (3) (the most successful) result or contribution in your thesis.

Keywords

Artificial intelligence, data mining, deep learning, neural networks


Poglavje 1

Uvod

Čeprav se so prvo barvno fotografijo naredili že leta 1886 [?], se je barvna fotografija v vsakdanji uporabi uveljavila šele mnogo kasneje. Tako imajo naši stari starši še vedno veliko črno belih fotografij. Ker te prikazujejo realnost povsem drugače, bi jih radi obarvali. Pa je to sploh mogoče?

Ta problem rešujejo algoritmi za barvanje črno-belih slik. Ti dobijo kot vhod črno-belo fotografijo, ki ji na to dodajo barvo, kot je prikazano na sliki 1.1. Algoritmi za barvanje črno-belih slik se uporabljajo na več področjih: barvanje starih slik, barvanje črno-belih filmov in v pomoč pri umetnosti. Za človeka je barvanje črno-belih slik, ki so prikazane na sliki 1.2, enostavna naloga. Z vsakdanjim opazovanjem sveta se je človek naučil, da je nebo modro z belimi oblaki, drevesa so zelena in cesta je siva. Za objekte, ki nimajo enolično določene barve ljudje lahko ugibamo kakšne barve naj bi predmet bil. Pri tem opraviu je potrebno veliko razumevanja, saj iz sivinskih slik ni možno direktno razbrati barv, namreč pri nastanku sivinske slike se veliko informacij izgubi (dve od treh dimenzij).

Problem postane bolj kompleksen, ko ga želimo rešiti na avtomatski način z računalnikom. Pri tem nam je v pomoč dejstvo, da je možno iz tekstur objektov te prepoznati in jim na ta način določiti njihovo barvo. Pri objektih, ki nimajo enolično določeno barv (na primer avtomobili, stavbe in knjige) je izziv še mnogo težji. Pri tem nam delo olajša dejstvo, da ne želimo, da slika




Slika 1.1: Algoritem za vhod vzame črno-belo (sivinsko) sliko, preko nivojev nevronske mreže določi barvne komponente in za konec združi sivinsko sliko z barvnimi komponentami.

zgleda enaka originalni ampak, da ta zgleda naravno. Nihče ne bo vedel, da je avtomobil, ki smo ga pobarvali rumeno bil v resnici rdeče barve.

Pri barvanju slik algoritmu, ki je zasnovan na podlagi nevronske mreže, podamo sivinsko sliko (L kanal barvnega prostora *CIE Lab*), sistem pa vrne a in b kanal v istem barvnem prostoru. Za treniranje modela potrebujemo veliko količino črno-belih slik z referenčno barvno sliko, kar je praktično zastoj na voljo na spletu. Za treniranje lahko vzamemo katerokoli sliko, jo pretvorimo v barvni prostor *CIE Lab*, kjer L kanal predstavlja sivinsko sliko.

V tej magistrski nalogi rešujemo problem barvanja črno-belih slik in videov z večimi različnimi implementacijami. Za začetek smo implementirali več algoritmov za barvanje črno-belih slik. Rezultate smo med seboj primerjali s računanjem razlike med obarvano in originalno sliko. Rezultate smo primerjali tudi z dvema implementacijama iz sorodnih del. Ker pa obstaja veliko objektov, ki nimajo enolične barve (avtomobili, zgradbe, ...) in naš namen ni doseči enakega barvanja, vendar takega, ki da naravne rezultate, smo barvanje slik ocenjevali s pomočjo uporabnikov. V spletni anketi smo



Slika 1.2: Primeri barvanja črno-belih slik. Barvanje je bilo izvedeno z algoritmi, ki so bili razviti v okviru te magistrske naloge. Za vsako sliko je prikazana črno-bela slika, ki je bila vhod v algoritem in obarvana slika - izhod algoritma.

uporabnike spraševali katera slika je bolj naravno obarvana (originalna ali slika obarvana z algoritmom).

Kasneje smo se odločili poskusiti tudi barvanja vida. Za barvanje smo arhitekturo nevronske mreže, ki je najbolj delovala na slikah prilagodili še za video.

Poglavje 2

Pregled Področja

2.1 Predstavitev slikovnih podatkov in barvni prostori

Slike, ki jih uporabljamo za učenje so shranjene v *RGB* [3] barvnem prostoru. Kot je pokazano v [4] se izkaže, da prostor RGB ni direktno primeren za učenje algoritmov za barvanje iz dveh razlogov:

- **Sistem se ne ujema dobro s človeško percepcijo barv**, saj so razdalje med enako sorodnimi barvami različne glede na odtenek [5]. Na primer, če imamo dva para barv rdečo in svetlo rdečo, ter modro in svetlo modro, pri čemer sta barvi v vsakem paru za človekov vizualni sistem enako različni, sta razdalji v RGB barvnem prostoru različni .
- **Nima ločenega kanala za svetlost** [3]. Glede na to, da modeli za barvanje napovedujejo le barvne elemente v sliki, svetlost pa se vzame iz originalne slike, je najbolj priročno, če uporabljamo barvni prostor, ki ima ločen kanal za svetlost.


Tabela 2.1: Največje in najmanjše vrednosti posamezne komponente CIE $L^*a^*b^*$ barvnega prostora, pri pretvorbi vseh barv iz barvnega prostora RGB. Pretvorba je bila narejena z uporabo osvetlitve $D65$, ki določa temperaturo bele točke.

Kanal	Najmanjša vrednost	Največja vrednost
L^*	0	100
a^*	-86.185	98,254
b^*	-107.863	94.482

2.1.1 Izbira primerne barvnega prostora

Na podlagi teh predpostavk je izbira prostorov omejena na Lab [6], YUV [?] in HSL [3]. Vsi ustrezajo drugi predpostavki iz 2.1. Edini, ki zares ustreza prvi predpostavki je Lab . Iz ugotovitev iz sorodnih del [4, 7, 8] se tudi najbolje izkaže prostor CIE $L^*a^*b^*$.

Obstaja več verzij barvnega prostora Lab , vendar se trenutno najbolj uporablja CIE $L^*a^*b^*$, ki naj bi bil najboljša aproksimacija človeškega vizualnega sistema [5]. Prostor ima to prednost, da je neodvisen od naprave. Prostor CIE $L^*a^*b^*$ predstavi vse barve, ki jih je možno zaznati z tremi barvnimi kanali. L^* predstavlja svetlost, a^* se razširja od zelene proti rdeči barvi in b^* od modre proti rumeni. L^* ser razteza od 0, ki predstavlja črno barvo, do 100, ki predstavlja belo barvo [?]. Prostor je grafično prikazan na sliki ?? a^* in b^* komponenti nimata uradne omejitve, vendar sta v implementacijah ponavadi omejene na vrednosti v intervalu $[-128, 127]$, kar je možno predstaviti z 8 bitnim celim številom [?]. Ker zaradi pretvorb iz barvnega prostora RGB vrednosti višje od 100 ali nižje -100 redko dosežemo smo opazili, da nekatere implementacije omejuje barvni prostor na interval $[-100, 100]$. Za pomoč pri implementaciji nevronske mreže smo sami preizkusili kakšen je dejanski interval barv pretvorjenih iz RGB barvnega prostora. Intervale si lahko pogledate v tabeli 2.1.



Slika 2.1: Slika prikazuje kanale barvnega prostora CIE $L^*a^*b^*$. L^* predstavlja svetlost, a^* se razteza od zelene barve v najbolj negativni točki proti rdeči barvi, b^* se razteza od modre proti rumeni. Nasprotujoče barve na kanalih a^* in b^* se nikoli ne kombinirajo v odtenek. Iz: Adobe, Technical Guid, CIELAB, http://dba.med.sc.edu/price/irf/Adobe_tg/models/cielab.html (dostopano: 24. junij 2017)

2.1.2 Pretvarjanje med RGB in CIE $L^*a^*b^*$ barvnim prostorom

Za pretvorbo med prostoroma ni enostavne enačbe, saj je *RGB* barvni prostor odvisen od naprav, *CIE $L^*a^*b^*$* pa ne. Tako se pretvorba zgodi v treh korakih [?]:

1. **Pretvorba iz RGB v sRGB ali Adobe RGB**, saj sta ta barvna prostora neodvisna od naprave. Ta pretvorba je odvisna od naprave. Slike, ki jih bomo uporabili v našem delu so že v sRGB obliki, saj so bile pretvorjene, ko so bile zajete z fotoaparatom.
2. **Pretvorba CIE 1931 barvni prostor** ali drugače imenovan XYZ barvni prostor. Ta pretvorba se izvede s pomočjo linearne pretvorbe z matriko. Matrika je odvisna od izbire referenčne bele barve. Običajno se izbere referenčno temperaturo belo točke *D65*, ki je tudi standardizirana¹[9].

¹Zapis na uradni strani komisije International Commission on Illumination (krajše CIE),

3. Pretvorba iz XYZ v $L^*a^*b^*$ se izvede po enačbah opisanih v [10].

2.2 Obstoječe metode za barvanje črno-belih slik

Metode za barvanje črno-belih slik delimo v dve večji skupini. Prva zahteva interakcijo uporabnika, pri drugi pa barvanje poteka popolnoma avtomatsko.

2.2.1 Metode, ki zahtevajo interakcijo uporabnika

To skupino metod delimo na tehnike, ki temeljijo na uporabnikovem barvanju manjših delov slik (ang. *scribble based*) [11, 12] in tiste, ki temeljijo na primerih (ang. *example based*) [13, 14, 15]. Pri prvih uporabnik določi barvo določenih točk v sliki, te pa algoritem avtomatsko razširi preko cele slike. Pri barvanju na primerih pa mora uporabnik izbrati sliko, ki je podobna tisti, ki jo želimo pobarvati, algoritem nato lastnosti izbrane slike razširi na drugo sliko ali množico slik. Tehnika barvanja s primeri se uporablja za barvanje videov, saj je v tem primeru potrebno ročno pobarvati na primer vsako stoto sliko, na ostale pa algoritem sam razširi lastnosti ročno barvane slike.

2.2.2 Popolnoma avtomatske metode

V magistrskem delu se osredotočamo na avtomatske metode barvanja. To so algoritmi, ki samostojno, brez uporabnikovega posredovanja, obarvajo celotno sliko. Prvi dve metodi, ki sta bili predlagani na tem področju, temeljita na značilkah (ang. *features*) pridobljenih iz slike. Tukaj gre predvsem za značilke, ki opisujejo intenziteto posamezne barve in opisnike, ki opisujejo robove v sliki. Prva metoda uporablja za barvanje nevronska mreža [16], ki pa vsebuje zgolj polnopravne nivoje, druga pa za barvanje uporabi metodo naključnih gozdov (ang. *random forest*) [17].

ki je postavila standard: http://cie.co.at/index.php?i_ca_id=484

Novejši pristopi barvanja črnobelih slik tipično temeljijo na konvolucijskih nevronskih mrežah, ki imajo to lastnost, da v vsakem nivoju same odkrijejo značilke, ki so pomembni. Prva tovrstna rešitev [18] gradi mrežo na podlagi že zgrajene šestnajst-nivojske mreže VGG-16, ki so jo razvili na univerzi v Oxfordu [19]. Rešitev uporablja evklidsko cenilno funkcijo in barvni prostor YUV. Slabost te rešitve je, da izhodne barvne slike niso dovolj nasičene.

V zadnjem času predlagane rešitve popravijo problem nenasičenosti z uporabo softmax funkcije v zadnjem nivoju nevronske mreže, kar pomeni, da so problem spremenili iz regresijskega v klasifikacijskega. Zang in sod. [20] uporabijo konvolucijsko nevronske mreže z več nivoji in aktivacijskimi funkcijami ReLU. Posebnost te mreže je cenilna funkcija. Uporablja križno entropijo, ki pa je v tem primeru izvedena na primerjavi barv posameznih delov slike glede na barvni prostor, ki je kvantiziran. Napake so pomnožene z utežjo, ki določa pogostost barve. Bolj redke barve so obtežene tako, da prispevajo večji delež k napaki, ki jo izračuna cenilna funkcija. S tem so avtorji izboljšali rezultate, tako da se bolj pogosto pojavljajo tudi močnejši odtenki (tisti z višjimi vrednostmi v prostoru $a*b^*$, ki so bili prej redkeje zastopani zaradi bolj pogostega pojavljanja nežnejših barv v slikah (barve bližje vrednostim $(0,0)$ v $a*b^*$ prostoru. Pogostost je bila izračunana z analizo vseh slik v podatkovni zbirki Imagenet [21]. Uporabljajo barvni prostor L^*a^*b . Larsson in sod. [22] za osnovo uporabijo mrežo VGG-16, iz katere vzamejo napovedi vsakega nivoja, ki jih združijo v enotno matriko. Sledi še en polno-povezan nivo na nivoju točk v sliki. Rezultat klasifikacije je histogram za vsako točko v sliki (histogram z verjetnostmi). Uporabljajo barvni prostor HSV. Cenilna funkcija, ki jo uporabljajo je KL-divergenca, ki primerja izhodni histogram z v histogram pretvorjeno originalno sliko. Iizuka in sod. [4] uporabijo nevronske mreže sestavljeno iz dveh delov. Prvi del poskrbi za napovedovanje vsebine slike, ki se potem združi z drugim delom in izboljša natančnost barvanja. Uporabili so križno entropijo (ang. *cross entropy*) v kombinaciji s cenilno funkcijo *povprečna kvadratna napaka* (ang. *Mean squared error*) in barvni prostor L^*a^*b . Za razliko od prejšnjih dveh metod zadnja ne napo-

veduje histograma na podlagi kvantiziranega prostora ampak direktno a^* in b^* vrednost, kar pomeni, da ne uporablja klasifikacije ampak regresijo.

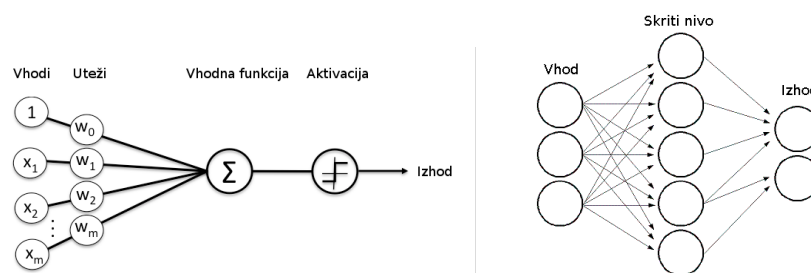
2.3 Globoke nevronske mreže

Globoke nevronske mreže so algoritmi, ki so zgrajeni na podlagi opazovanja strukture možganov. Veliko se uporabljajo za klasifikacijo, regresijo, gručenje in napovedovalno analizo. Predvsem se uporabljajo na področju slik, kjer je zelo pomembno prepoznavanje objektov in obrazov, razvrščanje slik v skupine glede na podobnost, prepoznavanje gest in barvanje slik [1].

Nevronska mreža je v osnovi funkcija $f(x)$, ki preslika vhod x v izhod y . Med postopkom učenja je ta funkcija optimizirana tako, da najde najboljšo povezavo med vhodnimi in izhodnimi podatki [1]. Nevronske mreže so ime za strukturo, ki je sestavljena iz več nivojev. Nivoje si lahko predstavljamo kot vrsto vozlišč, ki se odzovejo v primeru da je vzburjenje na njih zadovoljivo - odvisno od aktivacijske funkcije. Struktura vozlišča in nivojev je predstavljena na sliki 2.2. Vozlišče pomnoži vsak vhod s trenutnimi vrednostmi uteži, vrednosti sešteje in moč aktivacije izračuna s pomočjo tako imenovane aktivacijske funkcije, ki tvori izhod vozlišča. Aktivacijski funkciji rečemo tudi nelinearnot, saj poskrbi za to, da nevronska mreža ni le linearna funkcija. [?] Uteži se skozi postopek učenja spreminjajo in s tem določijo aktivacijo vozlišča.

Nivojem v nevronskih mrežah, ki se nahajajo med vhodnim in izhodnim nivojem rečemo *skriti nivoji* (angl. *hidden layers*) [?]. Tradicionalni algoritmi na področju strojnega učenja so sestavljeni iz vhodnega, izhodnega nivoja in enega skritega nivoja, *globoka nevronska mreža* (ang. *deep neural network*) pa ima vsaj dva skrita nivoja [?], večinoma pa mnogo več. Vsak nivo globoke nevronske mreže prepozna določen lastnosti vhodnih podatkov. Nivoji, ki se nahajajo globlje lahko prepoznajo bolj kompleksne lastnosti podatkov, saj na vhodu, dobijo lastnosti oziroma aktivacije nivoja pred njim.

Da nevronska mreža daje zadovoljive rezultate je potrebno utežem določiti



Slika 2.2: Leva slika prikazuje zgradbo enega vozlišča, ki ima znovno podobno nevronom v možganih, desna pa zgradbo več nivojske nevronske mreže. Iz: Introduction to Deep Neural Networks [urlhttps://deeplearning4j.org/neuralnet-overview](https://deeplearning4j.org/neuralnet-overview) in Neural Networks, [urlhttp://docs.opencv.org/2.4/modules/ml/doc/neural_networks.html](http://docs.opencv.org/2.4/modules/ml/doc/neural_networks.html) (dostopano: 21. junij 2017)

prave vrednosti. To naredimo s postopkom učenja. Vsaka nevronska mreža ima cenilno funkcijo (ang. loss function), ki pove kako dobre rezultate na testnih podatkih nevronska mreža daje trenutno. V postopku učenja zmanjšujemo vrednost cenilne funkcije z enim od algoritmov optimizacije.

2.3.1 Konvolucijske nevronske mreže

Ker bi bilo na primeru slik pri uporabi klasičnih nevronskih mrež hitro preveč parametrov, kar bi poleg podaljšanja časa učenja povzročilo tudi prekomerno prilagajanje (ang. overfitting), uporabljamo za take primere konvolucijske nevronske mreže. Te so zelo podobne običajnim nevronskim mrežam. Sestavljene so iz nevronov, ki imajo svoje uteži in bias, ki so učljivi. Operacije znotraj nevrona so podobne tistim pri običajnih nevronskih mrežah, le da so prilagojene pričakovanim vhodnim podatkom - slikam. Vhod v vsak nivo nevronske mreže je torej matrika z obliko *širina \times višina \times globina* [2]. Te so v osnovi sestavljene iz treh vrst nivojev:

- **Konvolucijski nivo** je glavni gradnik konvolucijske nevronske mreže. Parametri tega nivoja so sestavljeni iz majhnih konvolucijskih jeder, ki

pokrivajo majhno polje v širino in višino obenem pa pokrivajo celotni nivo v globino. Med prehodom po nevronske mreži izvedemo konvolucijo po celotni višini in širi vhodne matrike, po globini pa se te izhode teh konvolucij sešteje enako kot pri običajni nevronske mreži. Izhod konvolucije z enim setom jeder je dvodimenzionalna matrika. [?]

- **Pooling nivo** je namenjen pod-vzorčenju (ang. downsampling) na določenem nivoju. S tem zmanjšamo število parametrov, kar vpliva zmanjšanje računske zahtevnosti in prekomernega prilagajanja. Deluje na principu, da je točna lokacija značilke manj pomembna kot približna lokacija glede na ostale značilke. [?]
- **Polno povezni nivo** je nivo enak skritim nivojem pri klasični nevronske mreži. Uporabi se za zadnjih nekaj nivojev pri konvolucijski nevronske mreži.

Poglavje 3

Barvanje črno-belih slik z globokimi nevronskimi mrežami


3.1 Arhitekture

3.2 Pristop z regresijo

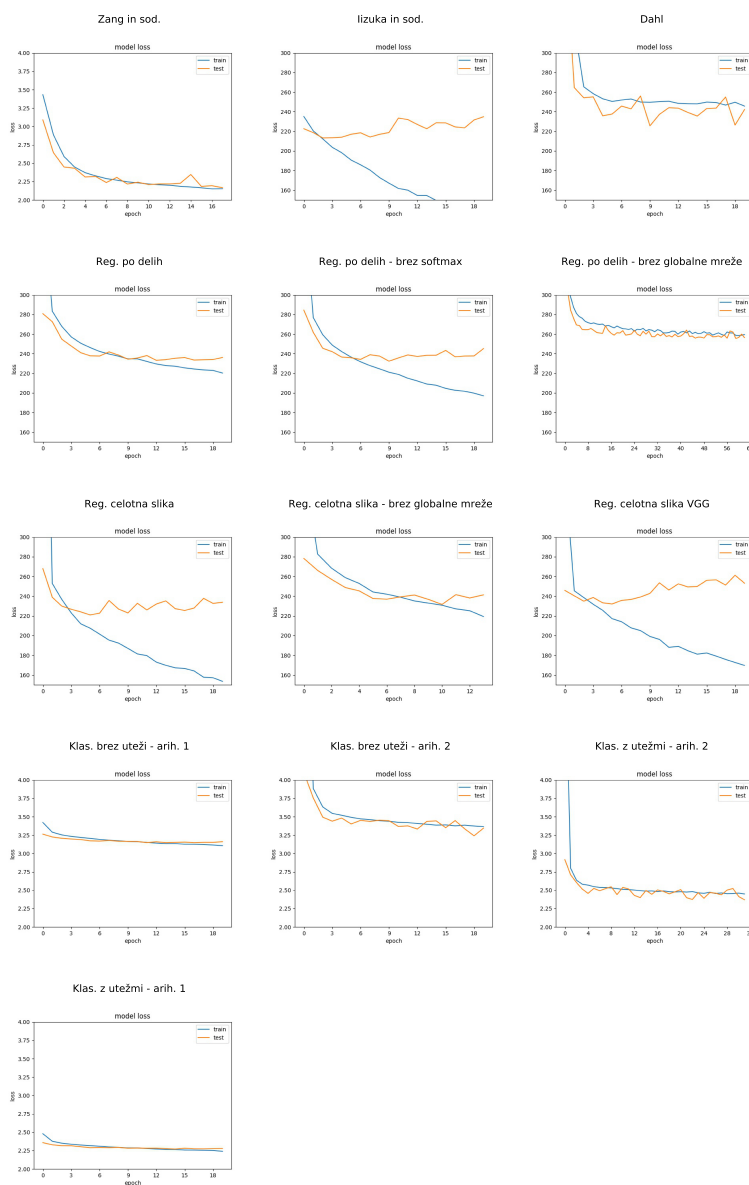
3.3 Pristop s klasifikacijo

3.4 Postopek učenja

Tukaj bi dali tudi slike po nivojih - kaj so znailke posameznega nivoja



Slika 3.1: Arhitektura 1



Slika 3.2: Prikaz padanja napake modela pri učenju. Za vsak prehod preko vseh podatkov (ang. *epoch*) je prikazana napaka na množici za treniranje in testni množici.

Poglavje 4

Podatki

Poglavje 5

Rezultati in diskusija

5.1 Primerjava metod na manjši učni množici


5.2 Primerjava metod na večji učni množici

Tukaj bi primerjali metode, ki bi bile naučene na več slikah, tako bi pridobili tudi boljša barvanja za pokazat izboljševanje barvanja glede na epoche. Primerjavo bi izvedli na manj manj metodah.


5.3 Barvanje večjih slik

Tabela 5.1: Napake izračunane na testni podatkovni zbirki.

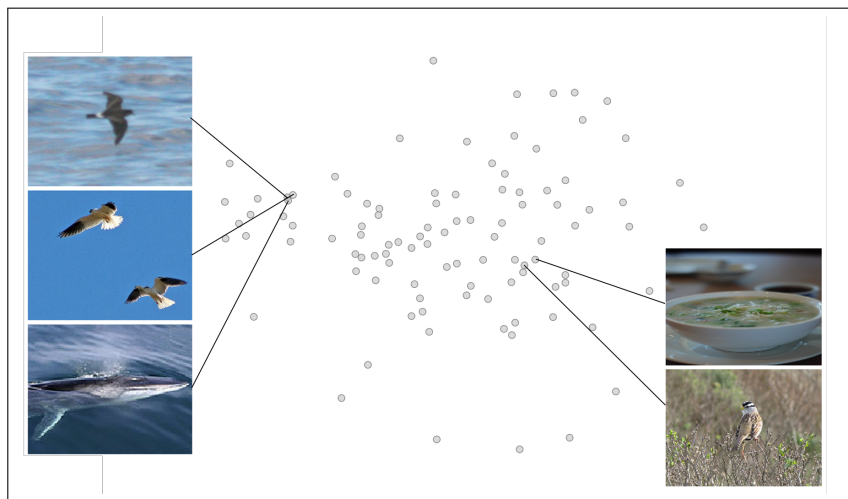
Metoda	RMSE	PSNR
Zhang in sod.	15.004	22.252
Iizuka in sod.	12.941	23.439
Dahl	13.936	22.551
Reg. po delih	13.216	23.199
- brez softmax	13.206	23.183
- brez globalne mreže	13.767	22.840
Reg. celotna slika	13.007	23.434
- brez globalne mreže	13.334	23.068
Reg. celotna slika VGG	13.387	23.131
Klas. brez uteži - arih. 1	14.336	22.738
Klas. brez uteži - arih. 2	15.086	22.380
Klas. z utežmi - arih. 1	14.573	22.610
Klas. z utežmi - arih. 2	15.137	22.395



Slika 5.1: Primerjava metod v prostoru MDS kaže sorodnosti med metodami na način napovedovanja barve (klasifikacija proti regresiji) in glede na arhitekturo mreže. Mreže, ki uporabljajo mrežo VGG za napovedovanje objekta v sliki so bližje skupaj in modeli brez VGG mreže so bližje skupaj.



Slika 5.2: Graf prikazuje rangiranje slik glede na napako $RMSE$ pri dveh različnih metodah. X os predstavlja rang pri prvi metodi, Y pa rang pri drugi metodi. Prva slika prikazuje primerjave rangov Dahlove metode in klasifikacijske metode z arhitekture 2. Druga metoda prikazuje range pri dveh klasifikacijskih metodah z istimi arhitekturami.



Slika 5.3: Razporeditev slik v prostoru MDS, ki zajema 100 sli, ki kjer natančnosti najbolj odstopajo pri različnih metodah. V prostoru so točke podobnih slik bližje skupaj. Dve taki podobni skupini slik sta prikazani ob robu.

Poglavje 6

Zaključek

Dodatek A

Spearmanova korelacija rangov med metodami

Tabela A.1: Spearmanova korelacija med metodami.

	Zang	Iizuka	Dahl	Reg. po de	Reg. po de	Reg. po de	Reg. celot	Reg. c
Zang in so	1.0000	0.8607	0.8688	0.8637	0.8407	0.8898	0.8779	0.880
Iizuka in	0.8607	1.0000	0.8936	0.9454	0.9420	0.9015	0.9472	0.920
Dahl	0.8688	0.8936	1.0000	0.9008	0.9058	0.9816	0.8889	0.951
Reg. po de	0.8637	0.9454	0.9008	1.0000	0.9440	0.9096	0.9392	0.914
Reg. po de	0.8407	0.9420	0.9058	0.9440	1.0000	0.9120	0.9313	0.919
Reg. po de	0.8898	0.9015	0.9816	0.9096	0.9120	1.0000	0.9005	0.964
Reg. celot	0.8779	0.9472	0.8889	0.9392	0.9313	0.9005	1.0000	0.914
Reg. celot	0.8804	0.9206	0.9518	0.9149	0.9194	0.9642	0.9140	1.000
Reg. celot	0.8969	0.9398	0.9196	0.9309	0.9211	0.9263	0.9334	0.937
Klas. brez	0.9092	0.9012	0.8636	0.9004	0.8795	0.8784	0.9030	0.875
Klas. brez	0.9409	0.8519	0.8861	0.8622	0.8434	0.8979	0.8657	0.865
Klas. z ut	0.9242	0.8535	0.8722	0.8578	0.8390	0.8817	0.8632	0.855
Klas. z ut	0.9023	0.8889	0.8431	0.8861	0.8640	0.8582	0.8904	0.854

Literatura

- [1] A. Gibson, C. Nicholson, J. Patterson, Introduction to Deep Neural Networks.
URL <https://deeplearning4j.org/neuralnet-overview>
- [2] A. Karpathy, CS231n Convolutional Neural Networks for Visual Recognition, University Lecture (2016).
- [3] N. Pm, R. M. Chezian, VARIOUS COLOUR SPACES AND COLOUR SPACE CONVERSION ALGORITHMS, Journal of Global Research in Computer Science 4 (1).
URL <http://jgrcs.info/index.php/jgrcs/article/viewFile/587/430>
- [4] S. Iizuka, Edgar Simo-Serra, H. Ishikawa, Let there be Color!: Joint End-to-end Learning of Global and Local Image Priors for Automatic Image Colorization with Simultaneous Classification, in: SIGGRAPH '16, Vol. 35, ACM, 2016, p. 110. doi:10.1145/2897824.2925974.
- [5] L. Prangnell, Visible Light-Based Human Visual System Conceptual Model.
URL <https://arxiv.org/pdf/1609.04830.pdf>
- [6] S. Bansal, D. Aggarwal, Color Image Segmentation Using CIELab Color Space Using Ant Colony Optimization.
URL <http://www.ijcset.net/docs/Volumes/volume1issue7/ijcset2011010715.pdf>

-
- [7] R. Zhang, P. Isola, A. Efros, Colorful image colorization, European Conference on Computer Vision.
URL http://link.springer.com/chapter/10.1007/978-3-319-46487-9_{_}40
- [8] G. Larsson, M. Maire, G. Shakhnarovich, Learning Representations for Automatic Colorization, arXiv preprint [arXiv:1603.06668](https://arxiv.org/abs/1603.06668).
URL <http://arxiv.org/abs/1603.06668>
- [9] N. Ohta, A. R. Robertson, Colorimetry: Fundamentals and Applications, Vol. null, 2005. doi:10.1002/0470094745.
URL <https://books.google.com/books?hl=en{&}lr={&}id=U8jeh1uhSHgC{&}oi=fnd{&}pg=PR2{&}dq=Colorimetry:+Fundamentals+and+Applications+{&}ots=SUbuB0kPfU{&}sig=FtBn43qgQvrKC0pXi71AeVB0FGk>
- [10] J. Schwiegerling, Society of Photo-optical Instrumentation Engineers., Field guide to visual and ophthalmic optics, SPIE, 2004.
URL <https://spie.org/Publications/Book/592975>
- [11] A. Levin, D. Lischinski, Y. Weiss, Colorization using optimization, in: ACM Transactions on Graphics (TOG), Vol. 23, ACM, 2004, pp. 689–694.
- [12] Y.-C. Huang, Y.-S. Tung, J.-C. Chen, S.-W. Wang, J.-L. Wu, An adaptive edge detection based colorization algorithm and its applications, in: Proceedings of the 13th annual ACM international conference on Multimedia, ACM, 2005, pp. 351–354.
- [13] M. Koleini, S. A. Mobadjemi, P. Moallem, Automatic Black and White Film Colorization Using Texture Features and Artificial Neural Networks, Journal of the Chinese Institute of Engineers 33 (7) (2010) 1049–1057.
- [14] P. Shirley, Color transfer between images, IEEE Corn 21 (2001) 34–41.

-
- [15] Y.-W. Tai, J. Jia, C.-K. Tang, Local color transfer via probabilistic segmentation by expectation-maximization, in: 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), Vol. 1, IEEE, 2005, pp. 747–754.
 - [16] Z. Cheng, Deep Colorization, in: CVPR, Vol. 1, 2015, pp. 415–423.
 - [17] A. Deshpande, J. Rock, D. Forsyth, Learning Large-Scale Automatic Image Colorization (2015). doi:10.1109/ICCV.2015.72.
 - [18] R. Dahl, Automatic Colorization.
URL <http://tinyclouds.org/colorize/>
 - [19] K. Simonyan, A. Zisserman, Very Deep Convolutional Networks for Large-Scale Image Recognition [arXiv:1409.1556](https://arxiv.org/abs/1409.1556).
URL <http://arxiv.org/abs/1409.1556>
 - [20] R. Zhang, P. Isola, A. A. Efros, Colorful Image Colorization, ECCV, 2016.
 - [21] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, L. Fei-Fei, ImageNet Large Scale Visual Recognition Challenge, International Journal of Computer Vision (IJCV) 115 (3) (2015) 211–252. doi: 10.1007/s11263-015-0816-y.
 - [22] G. Larsson, M. Maire, G. Shakhnarovich, Learning Representations for Automatic Colorization, arXiv preprint [arXiv:1603.06668](https://arxiv.org/abs/1603.06668).